

1 - Entrada

Cenas 3D reconstruídas (ScanNet). Lista de obj anotados (categorias, posição, bounding box)

2 - Consulta

Pergunta em linguagem natural ou forma estruturada, por exemplo distance(chair, table).

3 - Injeção de contexto espacial (SCI)

Geração de descritores L1(posição do obj), L2(ordem na categoria), L3(categorias vizinhas) e L2-Ref (restrito a consultas)

4 - Construção do prompt

Render top-down + consulta de obj + lista de objetos + descritores espaciais textuais.

5 - VLM / Grounding

interpreta o prompt, realiza o grounding, que seleciona as instâncias corretas dos objetos na cena.

6 - Cálculo de distancia geométrica

Carrega os pontos de superfície e mede distância entre as instâncias selecionadas. Também compara centroid e Axis-Aligned Bounding Box(AABB).

7 - Saída

Par de instâncias selecionado, distância em metros e resposta final da consulta.

8 - Avaliação

- Métricas de grounding(acerto de instância);
- Erro de distância (MAE);
- Sensibilidade à amostragem (análise de erro variando a densidade de pontos);
- Comparação com centroid e AABB.